

交通视频大数据应用研究进展

赵英¹, 王亚涛¹, 黄刚²

1. 北京同方软件股份有限公司, 北京 100083

2. 同方股份有限公司, 北京 100083

摘要 通过较为经济的方式实时感知交通路网运行状况是支撑交通安全畅通的基础条件, 而交通事件快速准确发现和交通数据及时可靠采集是其中的难点问题。传统的交通事件和交通数据监测采集方式在直观性、时效性、性价比等方面存在不同程度的提升空间。近年来, 视频大数据和人工智能的发展, 为上述问题的解决提供了新的思路。回顾了智能视频分析在交通领域的研究历史及应用局限, 提出了视频大数据的特征内涵, 设计了视频大数据驱动的人工智能平台, 展示了面向高速交通的解决方案及应用效果。

关键词 交通视频大数据; 人工智能; 深度学习; 云计算; 智慧高速

根据世界卫生组织和世界银行的报告^[1], 到2020年, 道路交通事故导致的人员伤亡, 将成为继心脏病、抑郁症后第3大影响人类健康和寿命的因素。在全世界范围内, 每天有超过3000人死于道路交通事故, 其中15~44岁占50%以上, 男性占比超过70%。该年龄段人员是一个家庭的主要经济收入来源, 其家庭成员的身心健康受到严重影响, 每年因车祸造成的经济损失占国民生产总值(GNP)的1%以上。截至目前, 道路交通事故依然是发病率和死亡率的主要因素^[2]。一项对欧洲研究的综述得出结论认为^[3], 约15%道路交通伤者于发生碰撞后4 h内死于医院, 35%于4 h后死亡。伤者应在14 min之内得到必要的紧急救护^[4]。因此, 及时发现交通事故并第一时间抢救, 将有望降低50%的交通事故死亡率。

发生在高峰期的交通事故, 很容易引发交通拥堵。美国交通运输部2006年的报告显示^[5], 美国高速公

路交通运输拥堵造成的货运耽搁、生产率下降、燃油浪费等经济损失年均达到2000亿美元。因此, 快速发现交通事故甚至预测预防交通事故, 不仅能降低死亡率, 还能减少大量经济损失。

20世纪70年代, 哈顿提出了著名的哈顿九宫格矩阵^[6], 列举了在交通事故发生前、发生时和发生后3个阶段中, 起到关键作用的3方面因素: 人、车和环境。如果掌握了哈顿矩阵中每一格需要的足够数据和科学方法, 该矩阵组成的9个格中, 每一个格都有机会通过干预措施减少伤害的发生, 道路交通事故是可以预测预防的。数据的全面性、实时性是影响预测预防的关键。

路网运行状态的实时监测, 将对降低交通事故二次事故损害发生、预测预防交通事故起到非常重要的作用。传统的路网交通事件发现和交通数据采集, 在实时性、性价比方面, 存在较大局限。如何获取高速路网实时运行状态, 已成为高速公路信息化建设亟待解

收稿日期: 2018-09-18; 修回日期: 2018-11-30

基金项目: 北京市科技计划项目(Z161100001116093); 国家科技重大专项(2018ZX01028102-003-002)

作者简介: 赵英, 高级工程师, 研究方向为智慧高速、视频大数据及人工智能, 电子信箱: ying13521396168@qq.com

引用格式: 赵英, 王亚涛, 黄刚. 交通视频大数据应用研究进展[J]. 科技导报, 2019, 37(6): 73-83; doi: 10.3981/j.issn.1000-7857.2019.06.010

决的问题。其中,实时获取交通流参数数据和实现对交通事件的实时检测是关键问题。

1 传统路网感知方法的局限

1.1 传统道路交通数据采集

传统道路交通数据采集手段分为安装到路面或路下的固定式检测和安装在车内的移动式检测2种(图1)。固定式检测分为侵入式和非侵入式2种方式^[7]。侵入式需要在路上放置传感器,非侵入式是基于远端观测的手段。侵入式主要包括:埋在车道下方、通过压力感应的气路管;将机械能转变为电能的压电式传感器;埋入车道的磁化线圈。非侵入式主要包括传统的红外探测,主动、被动红外探测器,被动磁,微波雷达,超声波,被动声波等手段。



图1 传统道路交通数据采集方法

Fig. 1 Traditional road traffic data acquisition methods

总体来讲,固定式检测手段所需安装维护费用较高,道路覆盖率较低,容易受天气和环境影响。具体局限性如下。

侵入式的检测手段,如橡胶气路管的检测手段,其覆盖的车道数量有限,容易受天气、温度和交通情况影响,并且不能完全适应低速车辆^[7];压电传感器的检测手段,只能测量重量和车速^[7];感应线圈是用量较大的传统交通数据采集方式,不受坏天气影响,但其寿命短、容易被重型车辆损坏且建设维护费高^[7]。

非侵入式的检测手段,如主动、被动红外探测可以检测车速、车辆类型。但天气不好时受影响,车道覆盖有限^[7];磁传感器(环形线圈)固定在路基上或下,记录车辆数量、车辆类型和车速,具有易于掌握、计数精确、

成本较低等优点,是目前世界上用量较大的检测设备^[8]。但是需要埋入车道、损坏路面、使用寿命短、车辆拥堵或车间距很近时(小于3 m),感应精度大幅降低^[7-8];微波雷达可以记录车辆数量、车速、车辆类型(简单分类),不受天气影响^[7],但需要装在路面上,需要改造公路基础设施;超声与被动声学探测手段容易受温度和坏天气影响^[7];被动声波设备安装在路边,可以检测车辆数量、车速及车辆类型,但受低温下雪影响^[7]。

移动(车载)检测指通过车载设备发送、接收数据的手段,又称为浮动车数据(floating car data, FCD)。通用的车载移动路网运行状况监测手段,是借助“主动式传感器”,例如基于雷达、基于激光、基于声音的传感器^[9]。主动式传感器是指向目标发射电磁波,然后收集从目标反射回来的电磁波信息的传感器,它们的主要优点是不需要大量计算。

雷达在雨天和雾天也能监测到150 m远的物体,而普通的司机只能看到10 m。激光雷达(light detection and ranging, LIDAR)更便宜,但在雨雪天的性能没有雷达好。激光比雷达更精确,但价格更贵。车载主动式传感器显示了很好的性能,但当装有这些传感器的汽车大量跑在路上时,传感器之间的干扰就成了大问题^[9]。

FCD的采集原理是通过车载GPS终端或手机信令定位车辆信息,并将这些浮动车的位置数据实时地传输到信息处理中心,从而实时获取交通拥堵信息。

浮动车数据包括基于GPS的浮动车数据和基于手机信令的浮动车数据2种方式。GPS方式定位精度高,但是费用较高,车辆安装数量不够多;浮动车数据采集交通数据时,精细度不够高,不能区分每条车道^[10]。基于手机信令的方式,安装和维护费用低,但是手机信令需要复杂的算法。

移动式检测的精细度依赖于安装的车辆数量,容易受到其他车辆的干扰。在某些偏远山区或农村,由于安装车载终端的车辆较少,数据采集质量受到较大影响。

传统固定式和移动式道路交通数据采集,普遍建设维护费用偏高,有些容易受到天气和温度的影响。表1^[7]总结了传统道路交通数据采集的局限。此外,传统道路交通数据采集手段展示的数据直观性较差、可读性不强。

表1 传统道路交通数据采集手段局限性一览表

Table 1 Limitations of traditional road traffic data acquisition methods

序号	传统交通数据采集		交通流量	车速	车辆类型	事件检测	受天气/温度影响	拥挤时适用	覆盖多车道	建设维护费	使用寿命(年)	
1	传统固定式	橡胶管	√	√	√	×	√	×	×	高	—	
2		侵入式 压电传感器	×	√	×	×	×	×	×	高	—	
3		磁化线圈	√	√	√	×	×			高	—	
4		非侵入式	人工计数	√	×	√	—	√	√	高	—	
5			红外探测	√	√	√	×	√		×	高	0.7~12
6			被动磁	√	√	√	×	—	×		高	—
7			微波雷达	√	√	√	×	×	—	√	高	10
8		超声	√	√	√	×	√	—	√	高	—	
9	传统移动式	浮动车	车载GPS	√	√	×	部分	—	√	√	高	—
10			车载手机信令	√	√	×	部分	—	√	√	—	—

1.2 交通事件间接检测方法

传统的道路交通事件自动检测方法,分为直接检测和间接检测^[11]。

直接检测指的是视频检测;间接检测方法指的是通过对采集到的交通数据挖掘分析,从而发现交通异常和交通事件的方法。交通数据的采集,是交通事件检测的前提条件和必备数据(图2)。

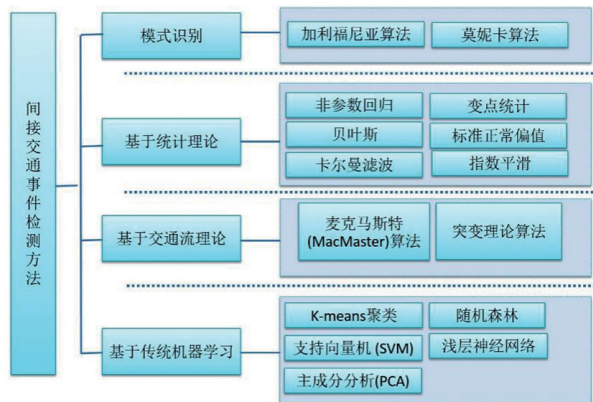


图2 间接交通事件检测方法

Fig. 2 Indirect traffic incident detection methods

如图2所示,间接方法主要包括以下4种方法。

模式识别算法:根据交通数据前后的差值判断是否为交通事件。其中,比较著名的有1965—1970年美国加利福尼亚运输部开发的加利福尼亚算法和莫妮卡算法。

基于统计理论的算法:包括非参数回归算法、变点统计算法、贝叶斯算法、标准正常偏值算法、卡尔曼滤波算法及指数平滑算法。

基于交通流理论的算法:包括麦克马斯特算法(MacMaster)和基于突变理论的算法。

基于传统机器学习的算法^[12]:包括以K-meas为代表的聚类算法、以支持向量机(SVM)为代表的分类算法^[13]、结合主成分分析(PCA)的算法、以随机森林为代表的集成学习方法^[14]及基于神经网络的交通事件检测方法^[15]。

根据道路交通数据采集的数据,采用间接检测方法,虽然可以实现对交通事件的检测,但检测的事件种类较为单一,对交通拥堵事件检测的效果较好,但无法实现对违章停车、行人穿越马路、车辆逆行等事件检测;检测出事件后,因为没有直观图像,无法立即验证事件的真伪,也无法实现对事件原因的分析;由于对拥堵检测依赖于车辆的排队长度和车辆速度,只有车辆积压到一定程度时才会报警,报警的时效性较差,也会存在对拥堵的漏报。

1.3 传统计算机视觉的应用局限

充分利用架设在道路上的视频摄像头,实现道路交通路网的智能感知,起源于20世纪90年代。主要实现对车辆及障碍物的检测,包括机动车、非机动车、行人;对路面和车道线的检测;对车辆的跟踪、识别;对交通行为的识别,如交通事件检测等几个方面。

早期的车辆、行人(障碍物)检测方法基于静止不动的摄像机,通过剔除背景、提取前景、提取全局或局部特征,然后经过模板匹配的方式,从图像中检出车辆^[16],然后进行分类。

对道路路面进行分割后,通过提取车道线的颜色

信息、外形信息等特征,进行车道线的检测^[17]。通常情况下,由于摄像机拍摄角度、车道线弯曲等情况,需要对图像进行逆透视变换^[10],消除图像远端直线交叉处的“灭点”后,再进行直线检测的方式。

检出车辆后,通常采用分类、模板匹配、自适应背景闪存^[18]等方式,对车辆进行识别^[19]。对车辆中的车牌进行识别,主要应用在摄像头离地面比较近的市内交通场景。车牌识别(automatic number plate recognition, ANPR; automatic license plate recognition, ALPR)受摄像机角度要求较高,但随着高清时代的到来,车牌识别已经趋于成熟稳定^[20]。

车辆跟踪简单分为单摄像头跟踪和跨多摄像头跟踪^[21-22]。单摄像头跟踪又分为跟踪单一目标的单目标跟踪和跟踪多个目标的多目标跟踪;跨多摄像头跟踪分为重叠多摄像头跟踪和非重叠多摄像头跟踪。重叠多摄像头跟踪,指的是同一目标同一时间出现在多个摄像头视域中,此时图像融合是研究重点;非重叠多摄像头跟踪指的是两个摄像头视域没有交叉,一辆车离开一个摄像头视域到另一个摄像头视域,中间有监控盲区,此时摄像头关联模型研究是重点。

车辆跟踪通常采用跟踪子特征的方式^[23],在高速公路上,通常采用背景估计、目标跟踪的方式。在城市道路上,为了更好地适应高密度车辆^[24],通常采用目标分类和3D建模方法^[25]。

跨多摄像头目标跟踪中的一个重要方向是目标重识别(re-identification, ReID)^[26],通常有基于特征的方法,即提取图像特征并对特征进行分类或验证。有传统特征提取方法^[27]和深度学习特征提取方法^[28];基于度量的方法,即比较两张图的相似度;基于视频序列的方法,即采用递归神经网络(recurrent neural networks, RNN)等深度学习方法^[29]等。

交通事件检测是更高层的图像理解,目前主要应用在高速公路上的突发事件检测^[24]。

利用路面摄像机实现对交通路网的实时感知,已经开始了实际应用。但人工巡检导致摄像机转动、大风等外部环境导致摄像机抖动时,算法的检测准确率会有很大程度下降,影响使用效果。此外,现有的算法在雨、雪、雾等不良天气下的检测性能,需要进一步提升。下雨、下雪容易导致路面及车道线被淹没或覆盖,影响对车速的检测精度;雾天导致车辆在图像中不够清晰,影响对车辆检测的精度。目前,大部分计算机视

觉系统有一定的错误率^[30],实时性和准确性都有待于提高。以上局限,在大数据时代,结合人工智能技术,有望得到解决。

2 视频大数据驱动的人工智能平台

2.1 交通视频大数据

2020年,中国高速公路将新增通车里程4.6万km,高速公路通车里程将达16.9万km^[31]。根据交通发展情况预测,未来高速公路,预计平均每2km将会有一路视频资源。预计到2020年,全国高速公路视频监控资源将会达到8万多路,分为观察型监控和分析型监控^[32]。按每路视频资源,每秒钟产生25张图片计算,每天每路视频摄像头,将会产生216万张图片。到2020年,全国高速公路,每天将产生1000多亿张图片。大数据技术和视频监控的结合,可以实现海量视频数据再分析利用,形成一个完整的大数据闭环应用,为视频监控业务创造更加智能、高效、安全的使用方式和提供更具方向性的决策^[33]。

视频大数据是典型的非结构化数据。视频大数据同样具有大数据的4个特征,即大容量(volume)、多样性(variety)、速度快(velocity)和价值高(value)。视频监控产生了海量的难以辨识的非结构化数据,随着物联网技术的发展,以及智慧交通的建设应用需求,将图像信息实时转化为大量的结构化数据,逐渐得到大规模实际应用,视频大数据从而诞生^[34]。视频数据的处理速度是影响视频大数据应用价值的关键因素。通过同方软件的视频数据采集技术,单路主频为1.9GHz的CPU每分钟分析9600张高清图片,即每分钟将会有9600张图片被处理成结构化数据。这些丰富的结构化数据可以存储一年甚至更长时间,积累成海量的结构化数据,具备实现大数据的基础^[35-36]。

为了提高视频大数据的实时处理和计算能力,视频大数据云计算中心应运而生,采用分布式计算框架完成视频大数据的处理和分析任务^[37],不仅提供高效的计算模型,还具备高效可靠的输入输出(IO),以便满足数据实时处理的需求(图3)。视频大数据云计算中心提供两类计算框架:大数据批量计算和大数据流计算。

大数据批量计算技术解决大规模、非实时数据计算问题,吞吐量是整个计算框架的重要指标。大数据批量计算技术的代表性框架包括MapReduce、Dryad、

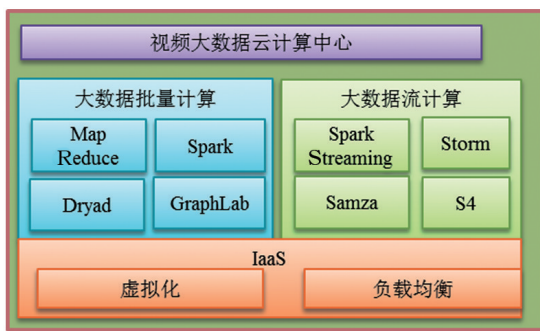


图3 视频大数据云计算关键技术

Fig. 3 Key technologies of video big data and cloud computing

Spark、GraphLab、flink等。

Hadoop的MapReduce具备低成本、高可靠性、高可扩展的特点,可以在大规模廉价的服务器上搭建起一个计算和IO处理能力强大的框架。更加关注数据中心内资源使用的公平性、执行环境的异构性和高吞吐的目标,提出公平调度、能力调度等计算任务调度器。

Dryad编程模型采用有向无环图(directed acyclic

graph, DAG)对任务的执行进行描述,用户指定的程序是DAG图的节点,DAG图的边是数据传输的通道。执行的任务是图的生成器,在执行的过程中这些图可以发生变化,以响应计算过程中发生的事件^[37]。

Spark采用基于DAG的编程模型,提供了丰富的编程接口。Spark可以在DAG图中划分不同的阶段,完成复杂应用的定义。在计算效率方面,Spark将结果及重复使用的数据缓存在内存中,减少了磁盘IO带来的开销,更适用于机器学习等需要迭代计算的算法;在容错性方面,Spark表现突出,数据以弹性分布式数据集(resilient distributed dataset, RDD)的形式存在,能够以操作本地集合的方式来操作^[37]。

相比于大数据批量计算技术关注数据处理的吞吐量,大数据流计算技术更关注数据处理的实时性,能够更加快速地为决策提供支持。大数据的流计算技术由复杂事件处理(complex event processing, CEP)发展而来,现在流计算的典型框架包括Spark Streaming、Samza、Storm、S4等。8种大数据计算框架的对比见表2^[37]。

表2 大数据计算框架对比

Table 2 Contrast of big data computing frameworks

计算框架	计算效率(实时性)	容错性	特点	适用场景
MapReduce	低	任务出错重做	编程接口简单,技术模型受限	文本处理、log分析、机器学习
Spark	高	RDD的Lineage保证	内存计算,通用性好,更适合迭代式任务	迭代式离线分析任务、机器学习
Dryad	较高	任务出错重做	针对Join进行了优化,允许动态优化调度逻辑(修改DAG拓扑)	机器学习、微软技术栈
GraphLab	较高	检查点技术	机器学习图计算专用框架	机器学习、大图计算
Storm	高	Worker重启或分配到新机器,任务重做	适用性好,消息传递可靠,支持热部署,主节点可靠性差	通用的实时数据分析处理
S4	高	部分容错,检查点技术	通用性较好,通信在TCP和UDP间权衡,持久化方式简单	实时广告推荐、容忍数据丢失
Samza	高	任务出错重做	可扩展性好,兼容流处理和批处理	在线和离线任务相结合的场景
Spark Streaming	低	RDD和预写日志(write ahead logs)	通用性好,容错性好,通过设置短时间片实现实时,应用较为局限	历史数据和实时数据相结合的场景

Spark Streaming计算框架在Spark的底层框架上构建了DStream的行为抽象。利用DStream所提供的应用程序编程接口(application programming interface, API),用户可以在数据流上实时进行操作^[37]。

Storm计算框架提供了可靠的流数据处理,可以用于实时分析、在线机器学习、分布式远程过程调用(re-

mote process call, RPC),数据抽取、转换、加载(ETL)等。Storm的缺点是集群存在负载不均衡的情况,任务部署不够灵活^[37]。

S4采用分散对称的架构,计算框架更加易于部署和维护。S4框架的主要缺点是持久化相对简单,数据存在丢失的风险;节点失败切换到备份节点之后,任务

都需要重做;缺乏自动负载均衡的相关能力^[37]。

针对视频存储的流式、非结构化特点,灵活运用集群化、虚拟化、离散存储、分布式存储等技术构建视频云存储中心。具备特点有:按需自动服务、丰富的资源池、快速灵活广泛的网络接入等。视频云存储是通过网络提供的可配置虚拟化存储和相关数据服务的存储方式,其服务级别可以按需要进行保证。视频云存储中心包括4层^[38]:以存储设备为代表的设备层,以虚拟化存储资源池为代表的存储层,以集群管理为代表的管理层,以及对外部应用提供的接口层。

庞大的视频图像资源,亟需转化为高附加值的结

构化数据,为交通规划、交通出行提供大数据的辅助手段。在视频大数据时代,云计算、大数据、物联网与视频业务融合发展^[39],驱动着智能视频分析算法的突破。交通视频大数据驱动的人工智能平台,主要解决分析型监控的实时性和高精度问题。

2.2 人工智能平台

视频大数据驱动的人工智能平台的总体技术架构如图4所示,从下到上分为视频大数据采集层,即云平台采集中心;视频大数据处理,即视频云计算中心;视频大数据存储,即视频云存储中心;视频大数据分析,即人工智能与机器学习、深度学习。

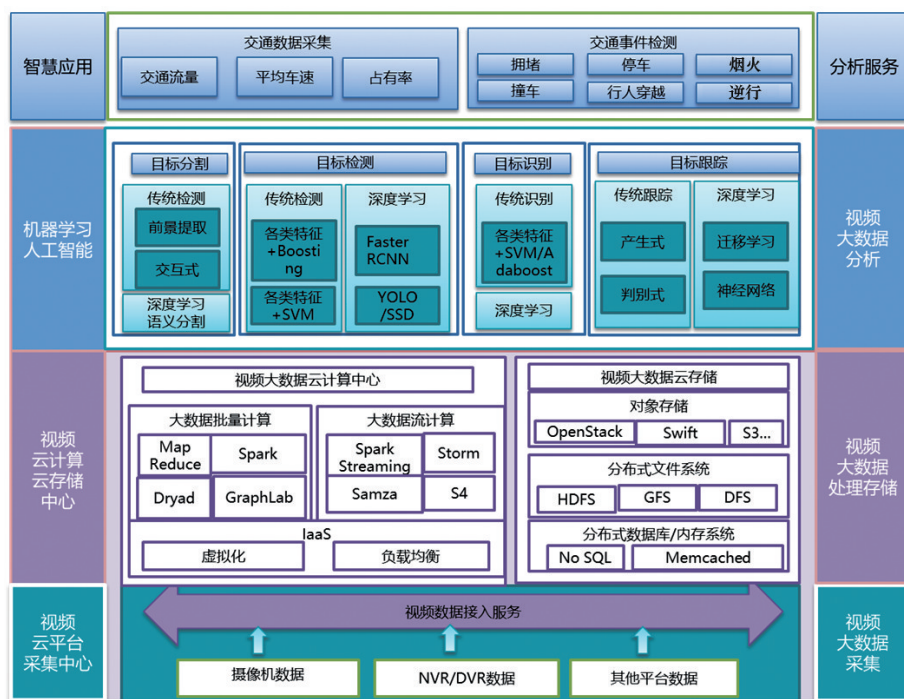


图4 视频大数据驱动的人工智能平台的总体技术架构示意

Fig. 4 Technical architecture of video big data driven artificial intelligence platform

视频云平台采集中心采集IP摄像机、硬盘录像机或其他平台的实时视频流,提供覆盖多种设备型号、不同类型设备的统一视频接入服务。

实时视频流、录像文件等,通过视频云计算中心实现对视频流的分布式计算和分析任务。视频大数据云计算中心的各计算节点,实现对视频数据的预处理,并基于机器学习实现特征提取,将视频大数据进行结构化处理。结构化的视频数据、非结构化的视频数据皆存储在分布式或集中式的视频云存储中心。

视频云存储中心包含数据保密性、完整性和可用性的数据安全机制^[40],采用用户身份认证技术、数据加

密技术、验证码技术、水印技术等,为用户数据安全性提供保障。

深度学习是一种机器学习的形态,强调高维的庞大的网络模型,模型中的参数通过从数据中学习获得,需要大量的可训练数据和强大的运算能力(图形处理器, GPU;神经网络专用芯片等)优化模型,可获得更高的精度。

采用人工智能机器学习技术,视频大数据分析典型的技术路线是:目标分割、目标检测、目标识别、目标跟踪。

1) 基于深度学习的目标分割:计算机视觉步入深

度学习时代之后,诞生了一系列基于卷积神经网络的语义分割方法,其中以全卷积神经网络(fully convolutional networks, FCN)、扩张卷积(dilated convolutions)为代表,采用条件随机场(conditional random field, CRF)为后处理操作,对语义预测结果进行优化,不断提升图像语义分割的精度。

2) 基于深度学习的目标检测识别:主流的目标检测方法分为2类:一类以R-CNN为代表,结合候选区域(region proposal)和CNN分类的目标检测框架,包括R-CNN (regions with convolutional neural network features)、SPP-NET、Fast R-CNN及Faster R-CNN等;第二类是以YOLO为代表,将目标检测转换为回归问题的目标检测框架,包括YOLO、SSD等。

3) 基于深度学习的目标跟踪:深度学习在目标跟踪领域的应用不够广泛和顺利^[24],主要问题在于训练数据的缺失。目前,基于深度学习的目标跟踪算法采用了几种思路来解决这个问题:(1) 迁移学习的思路,即利用辅助图片数据预训练深度模型,在线跟踪时微调,以DLT和SO-DIL为代表;(2) 卷积神经网络和观测模型相结合的思路,即在大规模数据集上训练出的CNN网络获得目标的特征表示,之后再用观测模型(observation model)进行分类获得跟踪结果,以FCNT^[22]为代表;(3) 深度特征和滤波器相混合,其主要思路是提取深度特征,之后利用相关滤波器确定最终的边界框(bound-

ing-box);(4) 运用递归神经网络(recurrent neural network)解决目标跟踪。

3 智慧高速应用实例

3.1 “云、边、端”架构及关键技术

目前高速公路路网监测与应急处置存在的局限包括:(1) 无法第一时间发现交通事件,影响应急处置时效,政府处置被动;(2) 海量视频依靠肉眼监测,无法避免疲劳导致的漏报;(3) 现有监测存在局限,即现有的车检器、浮动车、手机信令等监测手段普遍存在覆盖范围有限、易受天气影响、无法区分车道、维护困难等局限性;(4) 未充分利用海量视频进行交通参数的采集和统计,很难进行实时交通预测预警和研判。

针对以上问题,同方股份有限公司研发了面向智慧高速应用的视频大数据智能分析系统(“慧眼达”),充分利用高速公路外场现有摄像机设备,通过实时采集视频大数据,从海量的非结构化视频数据中,快速发掘出高价值信息,实现对交通事件的快速发现和报警,并实现实时交通数据采集。

“慧眼达”视频大数据智能分析系统的总体架构为“云平台+边缘计算+终端摄像机”的架构,即“云、边、端”架构(图5)。交通路网感知实时性的要求较高,需要在更贴近摄像机设备的网络边缘地方实时分析视频

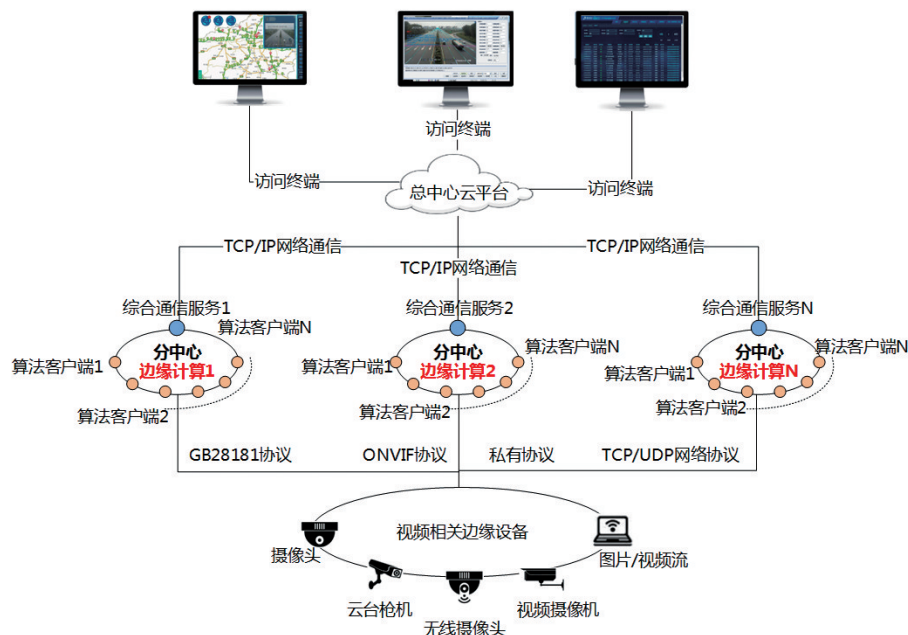


图5 “慧眼达”边缘计算架构示意

Fig. 5 Edge computing architecture of SighTA

流数据,完成数据运算。在高速路网的视频监控中,各高速路段的监控分中心处于网络边缘,“慧眼达”实时分析的算法程序部署在此。边缘计算作为一种本地化的分布式计算模式,不需要将数据发回云端及计算中心集中处理,提供了更快的响应速度,降低了总体安全风险。

部署在网络边缘的算法客户端,通过GB28181协议、onvif协议等,实现实时视频流的接入及算法分析,并将分析结果传至综合通讯服务器。综合通讯服务器实现客户端系统与业务应用系统之间的数据通信,并将实时分析数据汇总后推送至第三方业务系统。

业务应用系统部署在总中心的云平台上,以“一张图”的直观展示方式,供高速公路监管人员使用。业务应用系统将各算法客户端的分析结果进行集中展示,并对这些数据进行第二次深入分析。

本系统的研发,提出了一种基于深度学习及熵模型的交通事件视频检测技术,解决了局部区域和大范围交通事件的检测精度提升问题,使人工智能技术真正落地并应用到交通领域成为可能;提出了用图像全局特征构建空间熵模型的新方法,解决了大范围交通事件因“视频检测最开始的第一帧图像为交通拥堵”现象而导致的漏检问题;提出了采用时间域上事件的概率分布构建时间熵的新方法,提升了大范围交通事件检测精准度;提出了一种结合深度学习对交通事件检测的分类及时间、空间上的熵值综合分析交通事件的新方法,解决了图像中因大车占据面积过大而导致的拥堵误报问题,提升了局部范围交通事件的检测精度;提出了一种自适应场景切换的高速交通全车道线自动检测新方法,解决了因摄像机转动、道路复杂及极端天气下,或车道线磨损或物体遮挡导致车道线模糊或淹没等情况下无法用传统技术检测车道线的问题,让分车道交通流参数的精细化计算成为了可能,为补充甚至替代传统车检器奠定了技术基础^[10]。

3.2 检测精度及应用效果

系统在某省部署运行2年,覆盖全省>6000 km高速里程、23条主要干线、54个监控分中心、3500余路摄像机,实时监测全省高速全路网运行状况(图6)。

实现了对高速路网运行状况的自动化检测,对异常停车、撞车、交通拥堵、行人穿越等事件的智能化报警,交通参数的实时采集及统计(图7)。

截至2018年8月,交通数据采集总计超过7亿条,



图6 全路网运行实时监测(原型系统模拟)^[10]

Fig. 6 Real-time monitoring of road network operation

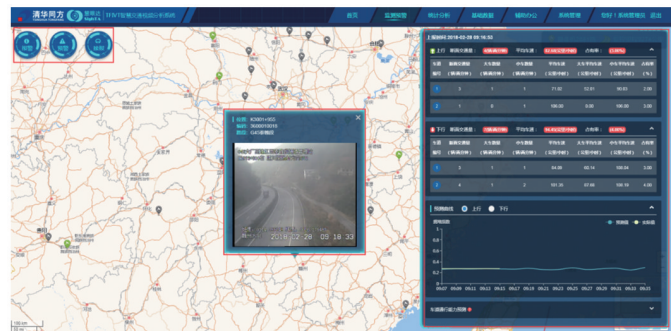


图7 交通数据实时采集(原型系统模拟)^[10]

Fig. 7 Real-time traffic data acquisition

分车道数据超过24亿条,检测出“雾天”报警数据近1900余万条,检测出交通事件2万起。

高速公路事故发生6 s内完成报警,1 min内自动完成事故原因分析,准确率超过93%。如图8所示,当系统自动检测到交通事件时,立即以声光报警的形式提醒监控人员,自动显示事件发生的地点,事发时各车道的交通流量、占有率等变化趋势。并自动生成事发时的录像和处置时的图像进行对比,有助于监控人员做出准确判断;自动显示事件类型、等级、位置、所属监控



图8 交通事件实时发现“一张图”(原型系统模拟)^[10]

Fig. 8 All-in-One picture of discovering traffic incidents in real-time

分中心等内容,并对事件原因、排队长度做进一步分析。根据以上信息,可以快速评估事件的影响范围、预估持续时长,监控人员可根据经验即时进行调整或确认,辅助路警联合指挥工作,快速发现并处置事件,最大程度地降低人员伤亡和财产损失。

对于各类不同的应用场景及复杂天气状况,系统具备自适应能力,无论是白天还是夜晚,雨天还是雪天,系统可自动切换至相应算法,将影响降到最低,从而真正实现全路网、全天候监测(图9)。



图9 全天候路网运行监测^[10]

Fig. 9 All-day road network operation monitoring

4 前景展望

以深度学习为代表的人工智能技术由于其精度高、鲁棒性强的特点,成为目标图像识别领域的主流算法,但是随着每个行业的典型应用不同,一些新的思想和算法在不断提出:例如,专门用于做目标检测的骨干神经网络,为目标检测的精度提升带来了新的方向;将一阶段(one stage)和二阶段(two stage)相结合的网络模型也在研究中;生成式对抗网络(perceptual GAN)也在尝试应用于对小物体的检测;将传统机器学习和深度学习相融合,兼顾计算资源的节省和检测性能的提升,也逐渐成为应用研究的方向。

深度学习的下一代发展,将有几个方向:帮助新任务解决训练样本不足等技术挑战的迁移学习;解决自动决策问题、提升自动设计分类网络能力的强化学习;利用对抗性行为加强模型的稳定性、提高数据生成效果的对抗学习。

计算机视觉在交通领域的研究,起源于20世纪80年代欧洲的“自动驾驶”汽车^[41],安装在汽车上的摄像头实现对路面的感知。计算机视觉应用在自动驾驶领域已经取得了很大进展,但在复杂市内道路交通环境中实现完全自动驾驶,目前还不够成熟。其中比较关键的问题是对道路感知的实时性和准确性,避免对路面判断的延时,避免对障碍物的漏报,避免对前后车辆的误报等,这些不仅依赖于算法的性能,更依赖于系统对庞大数据的融合分析及处理能力。随着视频大数据、人工智能技术的发展、带动数据处理能力的提升,自动驾驶将会逐渐应用到市内复杂环境的交通道路中。

新时代的交通规划、交通管理和控制服务,驱动着道路视频检测技术的进步。交通视频大数据驱动的人工智能技术为解决交通安全畅通提供了可能的途径。人、车、路的协同需求,将驱动着车载视频数据、道路视频数据的融合,形成交通大数据融合平台。未来对交通大数据的挖掘分析,将发现蕴含其中的交通规律、显式与隐式知识,可能颠覆现有的交通流理论体系,带动智能交通技术的创新发展。

参考文献(References)

- [1] Cameron M. World report on road traffic injury prevention[M]// World report on road traffic injury prevention. Geneva: World Health Organization, 2004: 270-275.
- [2] Kissi S, Fournier L, How N K. Road traffic accidents: A pictorial review[J]. Emergency Radiology, 2018, 25(4): 425-433.
- [3] Von H H, Al E. Reducing the severity of road injuries through post impact care[J]. European Journal of Emergency Medicine, 1999, 6: 271-274.
- [4] 杨惠敏, 陈雨人, 方守恩, 等. 高速公路交通事故救援时间与生存率关系模型研究[J]. 交通信息与安全, 2015(4): 82-86. Yang Huimin, Chen Yuren, Fang Shouen, et al. A Study of the relationship between rescue time and survival rate of traffic accidents on freeways using a cox regression model[J]. Transport Information and Safety, 2015(4): 82-86.
- [5] 寒金. 美国高速公路管理革新[J]. 交通企业管理, 2006, 21(9): 68-69. Han Jin. American highway management innovation[J]. Transportation Enterprise Management, 2006, 21(9): 68-69.
- [6] Haddon W. The changing approach to the epidemiology, prevention, and amelioration of trauma: The transition to approach-

- es etiologically rather than descriptively based[J]. American Journal of Public Health and the Nations Health, 1968, 58(8): 1431-1438.
- [7] Leduc G. Road traffic data: Collection methods and applications [Z/OL]. Working Papers on Energy, Transport and Climate Change, 2008, https://www.researchgate.net/profile/Guillaume_Leduc2/publication/254424803_Road_Traffic_Data_Collection_Methods_and_Applications/links/55645bf008ae6f4dcc99951f.pdf.
- [8] 邵春福, 赵熠, 吴戈. 道路交通数据采集技术研究展望[J]. 现代交通技术, 2006(6): 66-70.
Shao Chunfu, Zhao Yi, Wu Ge. Review of road traffic data collection technology[J]. Modern Transportation Technology, 2006 (6): 66-70.
- [9] Sun Z, Bebis G, Miller R. On-road vehicle detection: A review [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2006, 28(5): 694-711.
- [10] 赵英, 江龙, 王亚涛, 等. 视频大数据采集分析技术在高速路网安全畅通中的应用[J]. 中国交通信息化, 2017(增刊1): 143-147.
Zhao Ying, Jiang Long, Wang Yatao, et al. Application of video big data acquisition and analysis technology in safety and unblocked of highway network[J]. China ITS Journal, 2017 (Suppl 1): 143-147.
- [11] 张敬磊, 王晓原. 交通事件检测算法研究进展[J]. 武汉理工大学学报(交通科学与工程版), 2005, 29(2): 215-218.
Zhang Jinglei, Wang Xiaoyuan. Research progress of traffic incident detection algorithms[J]. Wuhan University of Technology (Transportation Science & Engineering), 2005, 29(2): 215-218.
- [12] Dogru N, Subasi A. Traffic accident detection by using machine learning methods[C/OL]. International Symposium on Sustainable Development, 2012, https://www.researchgate.net/publication/288511790_TRAFFIC_ACCIDENT_DETECTION_BY_USING_MACHINE_LEARNING_METHODS.
- [13] 武林芝, 陈淑燕, 郑小花. 基于PCA和SVM的交通事件自动检测算法[J]. 微计算机信息, 2010, 26(13): 220-222.
Wu Linzhi, Chen Shuyan, Zheng Xiaohua. Automatic incident detection algorithm based on PCA and SVM[J]. Microcomputer Information, 2010, 26(13): 220-222.
- [14] Liu C, Lu J, Chen S Y. Yesign and analysis of traffic incident detection based on random forest[J]. Journal of Southeast University (English Edition), 2014(1): 88-95.
- [15] 姜紫峰, 刘小坤. 基于神经网络的交通事件检测算法[J]. 长安大学学报(自然科学版), 2000, 20(3): 67-69.
Jiang Zifeng, Liu Xiaokun. Artificial neural network(ANN) algorithm for traffic incidents detection[J]. Journal of Chang'an University (Natural Science Edition), 2000, 20(3): 67-69.
- [16] Gupte S, Masoud O, Martin R F K, et al. Detection and classification of vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2002, 3(1): 37-47.
- [17] Cheng H Y, Jeng B S, Tseng P T, et al. Lane detection with moving vehicles in the traffic scenes[J]. IEEE Transactions on Intelligent Transportation Systems, 2006, 7(4): 571-582.
- [18] Karmann K P. Moving object recognition using an adaptive background memory[J]. Time-Varying Image Processing and Moving Object Recognition, 1990, 2: 289-296.
- [19] Lipton A J, Fujiyoshi H, Patil R S. Moving target classification and tracking from real-time video[C]//IEEE Workshop on Applications of Computer Vision. Piscataway, NJ: IEEE, 1998: 8-14.
- [20] 王潮, 宣国荣. 基于计算机视觉的实时交通流检测[J]. 计算机工程, 1997(增刊1): 276-278.
Wang Chao, Xuan Guorong. Real-time traffic flow detection based on computer vision[J]. Computer Engineering, 1997(suppl 1): 276-278.
- [21] 彭甜. 三个关键检测技术: 目标检测、目标跟踪和多摄像头协同[D]. 上海: 上海交通大学, 2010.
Peng Tian. Three key technologies: Target detecting, multi-targets tracking and multi-cameras coordination[D]. Shanghai Jiao Tong University, 2010.
- [22] 刘安安, 苏育挺. 跨摄像头的多运动目标跟踪方法: 102156863 B[P]. 2011-08-17.
Liu Anan, Sun Yuting. Multi-moving target tracking method across cameras: 102156863 B[P]. 2012-08-17.
- [23] Beymer D, McLauchlan P, Coifman B, et al. A real-time computer vision system for measuring traffic parameters[C]. Proceedings of IEEE Computer Society Computer Vision & Pattern Recognition, 1997: 495-501.
- [24] Buch N, Velastin S A, Orwell J. A review of computer vision techniques for the analysis of urban traffic[J]. IEEE Transactions on Intelligent Transportation Systems, 2011, 12(3): 920-939.
- [25] Hu W M, Xiao X J, Xie D, et al. Traffic accident prediction using 3-D model-based vehicle tracking[J]. IEEE Transactions on Vehicular Technology, 2004, 53(3): 677-694.
- [26] 罗浩. 基于深度学习的行人重识别研究综述[EB/OL]. (2017-12-10)[2018-9-12]. https://blog.csdn.net/baidu_18891025/article/details/79202249.
Luo Hao. Review of pedestrian recognition based on deep learning[EB/OL]. (2017-12-10)[2018-9-12]. https://blog.csdn.net/baidu_18891025/article/details/79202249.
- [27] Zapletal D, Herout A. Vehicle re-identification for automatic video traffic surveillance[C]//Computer Vision and Pattern Recognition Workshops. Piscataway, New Jencey: IEEE, 2016: 1568-1574.
- [28] Liu X C, Liu W, Mei T, et al. A deep learning-based approach to progressive vehicle re-identification for urban surveillance[C]//European Conference on Computer Vision. Cham: Springer, 2016: 869-884.
- [29] Zhou Y, Shao L. Vehicle re-identification by adversarial bi-directional LSTM network[C]//IEEE Winter Conference on Ap-

- plications of Computer Vision. Piscataway, New Jencey: IEEE, 2018: 653–662.
- [30] 自动驾驶计算机视觉研究综述: 难题、数据集与前沿成果[EB/OL]. (2017-09-13)[2018-9-12]. http://www.sohu.com/a/191792533_465591.
Research summary of computer vision for autonomous vehicle: Difficulties, data sets and forefront achievements[EB/OL]. (2017-09-13)[2018-9-12]. http://www.sohu.com/a/191792533_465591.
- [31] “十三五”末全国高速公路通车里程将达 16.9 万公里[EB/OL]. (2016-04-15)[2018-09-02]. <http://finance.sina.com.cn/roll/2016-04-15/doc-ifxrizpp1181339.shtml>.
By the end of the 13th Five-Year Plan, the mileage of national expressway will reach 169,000 kilometers[EB/OL]. (2016-04-15)[2018-09-02]. <http://finance.sina.com.cn/roll/2016-04-15/doc-ifxrizpp1181339.shtml>.
- [32] 何明. 智能交通基于视频、图像的大数据分析应用[J]. 智能城市, 2016(10): 112.
He Ming. Big data analysis and application of intelligent transportation based on video and image[J]. Intelligent City, 2016(10): 112.
- [33] 何志涛, 田铁红, 孙世臻, 等. 基于大数据技术的视频监控应用研究与探索[J]. 数字技术与应用, 2017(1): 95–96.
He Zhitao, Tian Tiehong, Sun Shizhen, et al. Research and application of video surveillance based on big data technology [J]. Digital Technology & Application, 2017(1): 95–96.
- [34] 赵英. 智慧城市与视频大数据[M]. 北京: 科学出版社, 2018: 86.
Zhao Ying. Smart city and video big data[M]. Beijing: Science Press, 2018: 86.
- [35] 黄海军. 浅谈安防大数据的应用[J]. 中国安防, 2016(5): 60–62.
- Huang Haijun. Talking about the application of big security data[J]. China Security & Protection, 2016(5): 60–62.
- [36] 何遥. 安防大数据的发展趋势[J]. 中国公共安全, 2015(22): 84–86.
He Yao. Development trend of security big data[J]. China Public Security, 2015(22): 84–86.
- [37] 赵晟, 姜进磊. 典型大数据计算框架分析[J]. 中兴通讯技术, 2016, 22(2): 14–18.
Zhao Sheng, Jiang Jinlei. Analysis of typical big data computing framework[J]. ZTE Technology Journal, 2016, 22(2): 14–18.
- [38] 海康视频云存储介绍[EB/OL]. (2014-9-11)[2017-11-25]. <https://wenku.baidu.com/view/a6c4c841a300a6c30d229f0f.html>.
Haikang video cloud storage introduce[EB/OL]. (2014-9-11)[2017-11-25]. <https://wenku.baidu.com/view/a6c4c841a300a6c30d229f0f.html>.
- [39] 舒文琼. 大视频元年已来服务质量评估需同步跟进[J]. 通信世界, 2016(30): 30.
Shu Wenqiong. Big video year has come, service quality assessment needs to be followed up synchronously[J]. Telecom World, 2016(30): 30.
- [40] 韩怿冰, 宋文军, 尚展垒. 云存储环境下的用户数据安全机制研究[J]. 网络安全技术与应用, 2016(4): 63–64.
Han Yibing, Song Wenjun, Shang Zhanlei. Research on user data security mechanism in cloud storage environment[J]. Practical Network Security Technology, 2016(4): 63–64.
- [41] Bertozzi M, Broggi A. GOLD: a parallel real-time stereo vision system for generic obstacle and lane detection[J]. IEEE Transactions on Image Processing A Publication of the IEEE Signal Processing Society, 1998, 7(1): 62.

Applications of traffic video big data

ZHAO Ying¹, WANG Yatao¹, HUANG Gang²

1. Beijing Tongfang Software Co., Ltd., Beijing 100083, China

2. Tongfang Co., Ltd., Beijing 100083, China

Abstract The real-time perception of the road network operation in a low-cost way is the key factor to guarantee the transportation safety and the unblocked operation. The rapid and accurate detection of traffic incidents and the collection of traffic data are often difficult. The traditional method is not visual, real-time and cost-effective. In recent years, the development of video big data and artificial intelligence provides a new way to solve these problems. This paper reviews the research history and application limitations of the intelligent video analysis in the field of transportation, as well as the characteristic connotation of video big data, the design of an artificial intelligence platform driven by video big data, and the solution and the application for highway traffic.

Keywords traffic video big data; artificial intelligence; deep learning; cloud computing; intelligent highway ●



(责任编辑 王志敏)